Tabla de contenido

RESUMEN **5**
1. INTRODUCCIÓN **6**
1.1 Contexto y antecedentes 6
1.2 Planteamiento del problema 7
1.3 Objetivo general 8
1.3.1 Objetivos específicos 8
2. ANTECEDENTES **9**
2.1 Marco teórico 9
2.1.1 Libranza 9
(TransUnion, 2022) ..... **¡Error! Marcador no definido.**
2.1.2 Solicitudes 9
2.1.3 Tiempo estándar 10
2.1.4 Aplicativo ..... **¡Error! Marcador no definido.**
2.1.5 Series de Tiempo 11
2.1.6 Modelos de Forecasting 12
2.1.7 Métodos de Suavización 12
2.1.8 Modelos Arima 13
2.1.9 Modelos de Machine Learning (ML) 14
2.1.10 Métricas 15
2.2 Estado del arte 16
3. METODOLOGÍA **19**
3.1 Esquema de trabajo 19
3.2 Fases del Proyecto 19
3.2.1 Fase 1: Comprensión del negocio 20
3.2.2 Fase 2: Comprensión de los datos 20
3.2.3 Fase 3: Preparación de los datos 20
3.2.4 Fase 4: Modelado 20
3.2.5 Fase 5: Evaluación 20

3.2.6 Fase 6: Despliegue 21

4. DESARROLLO 22

4.1 Entendimiento del negocio..... 22

4.2 Recolección y Entendimiento de los datos..... 23

4.3 Preparación de los datos 30

4.4 Modelado..... 35

4.5 Evaluación de los modelos 35

4.5.1 Modelos Estadísticos..... 35

4.5.2 Modelo de Machine Learning Autoregresivo Univariado y con Dos Variables Externas40

4.6 Resumen de resultados y Pronóstico con modelo seleccionado..... 44

4.7 Despliegue de la iniciativa 46

5. CONCLUSIONES Y TRABAJO FUTURO..... 49

6. BIBLIOGRAFÍA..... 52

Lista de tablas

Tabla 1 Fases y objetivos asociados según CRISP-DM Fuente: Elaboración propia 21
Tabla 2 "Diccionario de datos" Fuente: Elaboración propia 24
Tabla 3 "Resumen descripción de los datos" 31
Tabla 4 "Resultado prueba ADF" 34
Tabla 5 "Configuración de los datos para la evaluación de modelos" 35
Tabla 6 Resumen Resultados Elaboración Propia 45

Lista de ilustraciones

Ilustración 1 "Flujo de trabajo para modelos de Machine Learning" 15

Ilustración 2 Conceptos básicos de ayuda de CRISP-DM Fuente: IBM 19

Ilustración 3 Diagrama de flujo del proceso Fuente: Elaboración propia 22

Ilustración 4 "Flujo general del proceso de desembolso" 23

Ilustración 5 "Serie de Tiempo con Frecuencia Diaria – Sin Procesar " 25

Ilustración 6 "Distribución de la cantidad de solicitudes de desembolso" 26

Ilustración 7 "Distribución mensual de solicitudes de desembolso"..... 27

Ilustración 8 "Frecuencia de la variable Regional Radicación" 27

Ilustración 9 "Frecuencia de la variable CANAL_VENTA" 28

Ilustración 10 "Frecuencia de la diferencia de días entre Fecha radicación y Fecha desembolso" 29

Ilustración 11 "Serie de tiempo Radicación vs Serie de tiempo Desembolso"..... 29

Ilustración 12 "Comparación temporal series de tiempo" 30

Ilustración 7 "Descomposición de la serie de tiempo" Fuente: Elaboración propia..... 32

Ilustración 8 "Gráfico de Autocorrelación para la serie de tiempo"..... 33

Ilustración 9" Gráfico para el modelo media móvil con MSE = 0,4991" 36

Ilustración 10 "Gráfica Suavización exponencial Simple MSE = 0.546" 37

Ilustración 11" Gráfica Suavización Holt-Winters MSE = 0,396" 38

Ilustración 12 "Gráfica ARIMA resultado MSE=0.682" 39

Ilustración 13 "Gráfica Forecaster Autoregresivo con Random Forest resultado MSE=0.224" 41

Ilustración 14 "Gráfica Serie de tiempo Libranza, IPC e IBR" 41

Ilustración 15 "Gráfica Forecaster Autoregresivo con Random Forest + exógeno resultado MSE=0.2641"..... 42

Ilustración 16 "Gráfica Forecaster Autoregresivo Directo con Lasso resultado MSE=0.2934"¡Error! Marcador no definido.

Ilustración 23" Gráfica LSTM con MSE = 0.46"..... ..¡Error! Marcador no definido.

Ilustración 24 "Gráfica modelo Profeta con MSE = 0.433" .....¡Error! Marcador no definido.

Ilustración 25 "Análisis descriptivo de los datos" 47

Ilustración 19 "Resumen de lo obtenido por los modelos de machine learning" 48

RESUMEN

Se abordó la necesidad de una entidad bancaria de pronosticar la demanda diaria de solicitudes de desembolso de créditos de libranza y calcular la cantidad de personal requerido para atender dichas solicitudes. Para ello, se propuso una metodología CRISP-DM que involucró la extracción y limpieza de datos, así como la aplicación de modelos estadísticos de series de tiempo y de machine learning.

Se evaluaron modelos como el promedio móvil simple y la suavización exponencial, los cuales no lograron capturar adecuadamente los datos atípicos y las estacionalidades presentes en los datos. El modelo ARIMA también fue utilizado, pero su desempeño se vio afectado por las estacionalidades que no se pudieron equilibrar con los hiperparámetros del modelo. Por otro lado, se emplearon modelos de machine learning como LSTM y algoritmos de regresión de la librería skforecast, los cuales mostraron resultados más favorables. Específicamente, el modelo de Regresión Forecaster Autoregresivo obtuvo un error MSE de 0.2246.

Una vez identificado el mejor modelo, se realizó un cálculo utilizando los tiempos estándares para determinar la cantidad de personal necesaria para la atención. Los resultados obtenidos respaldan la idoneidad del enfoque de la solución propuesta.

En conclusión, este trabajo de grado abordó la necesidad de pronosticar la demanda diaria de créditos de libranza y calcular la cantidad óptima de personal requerido para su atención. La metodología CRISP-DM fue aplicada con éxito, y se demostró que los modelos de machine learning, en particular el Regresión Forecaster Autoregresivo, brindaron mejores resultados en comparación con los modelos estadísticos tradicionales. Estos hallazgos contribuyen a mejorar la eficiencia y planificación en el área de créditos de libranza de la entidad bancaria.

1. INTRODUCCIÓN

1.1 Contexto y antecedentes

El sector bancario tradicional en Colombia ha estado cediendo terreno desde la llegada de las Fintech al mercado, estas últimas han estado teniendo fuertes crecimientos en la cantidad de clientes y la pandemia ayudó a consolidar esta tendencia, (Nathalia Morales Arévalo, 2022) sin embargo, estos bancos siguen teniendo ventaja competitiva para algún segmento de clientes para el cual no es negociable la presencialidad, es decir, que al tener oficinas presenciales a nivel nacional estos clientes aún desean atención directa. Igualmente, esta banca ha hecho esfuerzo para evolucionar al ritmo del mercado y ofrecer productos digitales, en efecto esto ha impactado directamente la operación bancaria interna de áreas operativas. Puesto que, exigir un esfuerzo digital a una empresa que inicialmente no nace así, tiene ciertos impedimentos y/o inconvenientes a nivel de cultura organizacional, costumbre o arraigo en procesos que siempre han hecho de la misma manera y además procesos operativos que no están pensados para la era digital. Por lo que al final, la gerencia espera resultados transversales y que los clientes obtengan productos digitales y experiencia ágil de cara a su entidad bancaria, y se termina generando presión a las áreas operativas para que actúen con mayor eficiencia o productividad.

La productividad, tiene como objetivo medir el rendimiento de los colaboradores, maquinaria y procesos en general. Teniendo en cuenta lo anterior, las personas encargadas de la revisión y aprobación de los créditos son sujetos de medición de productividad dado que, a pesar de la automatización de algunos procesos, aún existen tareas que dependen de una realización manual por parte de estas personas. Esta medición normalmente se realiza sobre un total de servicios producidos por un factor de recursos durante un periodo de tiempo determinado.

Actualmente la medición de productividad es presentada a la gerencia desde dos fuentes de información, una fuente de elaboración manual en Excel y otra fuente con datos desde el aplicativo de registro de los servicios. Estas mediciones difieren en resultado, teniendo la primera un rendimiento del 100% y la segunda un rendimiento deficiente, por lo que la alta gerencia está en busca de alguna herramienta que le permita automatizar el proceso de medición de productividad y adicional le permita saber los requerimientos de personal para brindar un buen servicio al cliente.

En un mercado dinámico, cambiante y en el que la tecnología cada día cobra mayor relevancia, para la alta gerencia y la organización en general es un reto encontrar un balance entre el factor humano y las tecnologías que le permitan desarrollar herramientas para tomar mejores decisiones para el negocio y sus clientes.

1.2 Planteamiento del problema

La organización tiene una normativa de experiencia al cliente, la cual establece que los desembolsos se deben realizar máximo al tercer día hábil después de la radicación (las radicaciones llegan directamente por el aplicativo especializado). El área de Desembolsos se divide por producto bancario, cada uno cuenta con un líder y un equipo que puede rotar y ser prestado a un área que necesite la capacidad de la persona para atender solicitudes.

Además, el área cuenta con dos orígenes de datos para medir la productividad en la atención de las solicitudes con base en el tiempo estándar y meta establecida los cuales son: su propia base de datos automática (Aplicativo) y base manual de Excel. A partir de este último se genera un informe que es presentado a la Gerencia. En este, posterior a la realización del

trabajo de campo, se identificó irregularidad en el resultado. Lo anterior dado que, el índice de atención no cumple con los tiempos y la meta establecida.

Sin embargo, se indagó con la directora de la división quien afirmó que tienen una política de productividad establecida por el área experta, la cual fijó que los auxiliares deben atender 40 solicitudes diarias y solo reciben solicitudes hasta las 3:00 pm. La anterior métrica podría replantearse, dado que si a las 10:00 am ya han atendido 20 solicitudes, los auxiliares no estarían atendiendo más y a pesar de tener aún tiempo disponible para atender, se estaría cumpliendo con la productividad.

La pregunta que se pretende resolver es: ¿Cómo identificar la cantidad de personas necesarias que garanticen la atención de la demanda de solicitudes diarias de desembolso del área de libranza de acuerdo con el historial del aplicativo?

1.3 Objetivo general

Identificar a través del pronóstico de la demanda de solicitudes de desembolso del área de libranza, la capacidad máxima del recurso humano necesario para la atención de dichas solicitudes.

Comentado [Ui1]: Alineado con el comentario anterior. El proyecto consiste entonces en dos puntos i)Predicción de solicitudes de desembolso i) cálcular capacidad operativa ?

Comentado [PF2R1]: Si

1.3.1 Objetivos específicos

- Identificar modelos de serie de tiempo para la variable demanda de solicitudes de desembolso para pronosticar su comportamiento.
- Identificar y evaluar los modelos a través de métricas que permitan establecer el mejor pronóstico de la variable objetivo.

Comentado [PF3]: Cambiamos los objetivos específicos de forma

- Calcular cantidad de personas necesarias para atender la demanda pronosticada de solicitudes de desembolsos de acuerdo con métrica estándar.
- Realizar una visualización en Power Bi del pronóstico de demanda y la cantidad de personas requeridas.

2. ANTECEDENTES

2.1 Marco teórico

2.1.1 Libranza

Actualmente el Entidad financiera tiene una línea de crédito para Libranza, cuyo objetivo es prestar dinero a Personas naturales que estén vinculadas a empresas que tengan convenio con la organización, este tipo de crédito representa un menor riesgo puesto que se descuentan mensualmente de la nómina o mesada pensional del cliente (Nathalia Morales Arévalo, 2022), asegurando de esa manera la cancelación de las cuotas mensuales.

2.1.2 (TransUnion, 2022)Solicitudes

Las solicitudes de crédito son radicadas vía Aplicativo al área de Desembolsos por tardar a las 4:00pm aquellas operaciones ocurren de lunes a sábado. Se manejan por "Bolsa de Trabajo" donde cada Auxiliar debe reclamar la solicitud a validar. El orden de atención de las solicitudes es definición del Área (Fecha de vencimiento, ciudad, monto, status, reingreso etc.). Cada requerimiento cuenta con un numero único que identifica el crédito, por lo que cada registro corresponde a la solicitud de libranza. (Proceso Operativo). Estas solicitudes de demanda hacen referencia a la variable objetivo del presente estudio, por lo que se deben

considerar la cantidad de iteraciones en la que ocurre una solicitud por día para tenerla como parámetro para los modelos que se desarrollan en el transcurso del documento.

2.1.3 Tiempo estándar

En definición el tiempo estándar es el tiempo requerido para una operación bajo tres condiciones (Verbel Castellar, 2007):

- El trabajador debe estar calificado y capacitado.
- La velocidad de trabajo debe hacerse a un "ritmo normal".
- La operación debe estar normalizada.

De acuerdo con lo anterior, el tiempo estándar por operación es de 20 minutos, sin embargo, las variaciones en el número de solicitudes atendidas son las que dificultan a la hora de hacer un pronóstico de venta o determinar las personas que estarán disponibles para atender solicitudes, puesto que, el valor determinado y el número de solicitudes al día no coinciden certeramente.

2.1.4 Aplicativo

Todo el proceso se realiza directamente en un Core banking software que establece ventajas competitivas en la organización sobre otros, uso integral de los servicios de la nube y la optimización de costos de operación (Oracle, 2022). La parametrización del aplicativo permite descargar informes o querys con la información más relevante, esta información incluye una a una las solicitudes radicadas por el aplicativo, la hora y fecha, por lo cual estos informes son presentados a la gerencia para evaluar resultados de productividad.

2.1.5 Series de Tiempo

Comentado [PF4]: Se adiciono Series de tiempo

Las series de tiempo son un conjunto de observaciones o datos tomados en unos intervalos de tiempo definidos ya sean diarias, semanal, mensual o anual de una variable de interés. (Douglas C, Cheryl L, & Murat, 2009). Estas observaciones pueden ser de cualquier variable, como precios de acciones, temperatura o ventas de un producto. El análisis de series de tiempo es una técnica estadística que se utiliza para entender la evolución temporal de una variable y para predecir su comportamiento futuro.

Las series de tiempo además se pueden descomponer para realizar un análisis más detallado del comportamiento, evolución y estructura de la serie, lo cual facilita su entendimiento y puede ayudar para predecirla. Los principales componentes de una serie de tiempo son los siguientes (Chatfield C. &., 2013):

- **Tendencia:** Existe tendencia cuando en la serie se observa a largo plazo que los datos muestran una dirección con sentido crecimiento o decreciente, pero también se puede decir que la tendencia en lineal o no lineal con relación al patrón de comportamiento que muestran.
- **Estacionalidad:** La estacionalidad se refiere a un patrón en los datos que está ligado directamente con factores que se repiten en un periodo de tiempo conocido como época de vacaciones, estaciones del año, periodos escolares, épocas de cosecha, etc. Estos patrones pueden ser diarios, semanales, mensuales, trimestrales, anuales, etc.
- **Ciclos:** Los ciclos suelen ser difíciles de identificar en series de tiempo con pocos datos, normalmente están asociados con patrones que muestran los datos en el largo plazo, por ejemplo, los ciclos solares que se repiten cada 10 años.

- **Residuos o variación irregular:** Esta asociada a cambios en el patrón de los datos que no pueden ser explicados por la tendencia, estacionalidad o ciclos. Normalmente se deben a cambios inesperados como, por ejemplo, cambio en condiciones económicas, desastres naturales o disturbios públicos.

2.1.6 Modelos de Forecasting

Tal como lo definen en (Esan, 2019) *"El forecast es una herramienta muy útil en áreas de logística, ventas, finanzas, entre otras. Permite reducir la incertidumbre por medio de comparativas de datos empresariales y de mercado para luego establecer un calendario y estrategia. Sin embargo, también es necesario aplicar la técnica correcta de forecasting según el objetivo que tenga la organización."*

Por lo anterior, se concluye que es importante realizar modelos de Forecasting adecuados a los datos que se tengan en la investigación para que este resultado pueda generar el valor esperado, además que la predicción de los datos futuros puede ser adecuada o no según el proceso que se realiza, sin embargo, siempre se tendrá que considerar un grado de incertidumbre con el que vayamos a presentar el resultado de valores o eventos predichos.

2.1.7 Métodos de Suavización

Existen técnicas de pronósticos clasificados en los métodos de suavización que usualmente se utilizan para predecir valores futuros de las series de tiempo. Algunas desventajas de los métodos de suavización es que la estimación de los datos se hace respecto a la tendencia y/o patrones que tengan los datos históricos, sin embargo, son convenientes cuando los datos poseen una gran variación entre ellos y son difíciles de calcular por su precisión y exactitud.

- **Suavizado Exponencial**

El suavizado exponencial se propuso a fines de la década de 1950, los pronósticos producidos usando métodos de suavizado exponencial son promedios ponderados de observaciones pasadas, y los pesos decaen exponencialmente a medida que las observaciones envejecen. Este método es adecuado para pronosticar datos sin tendencia clara o patrón estacional. (Rob Hyndman, 2008).

- **Media móvil**

Un modelo de promedio móvil usa errores de pronóstico pasados en un modelo similar a la regresión. Se usa un modelo de promedio móvil para pronosticar valores futuros, mientras que el suavizado de promedio móvil se usa para estimar el ciclo de tendencia de valores pasados. Este método es muy simple y es útil para datos con fluctuaciones aleatorias. Sin embargo, no funciona bien con datos con tendencias. (Chatfield C. , 2003).

- **Suavización de Holt**

Este método extiende la suavización exponencial para incluir una tendencia lineal en los datos. Es útil para datos con tendencias. (Jr Everette S, 1985).

- **Suavización de Holt-Winters**

Este método extiende la suavización de Holt para incluir patrones estacionales en los datos. Es útil para datos con tendencias y patrones estacionales. (Everette S & Ed, 1985).

2.1.8 Modelos Arima

ARIMA es un acrónimo de Auto Regressive Integrated Moving Average, es de los modelos más famosos usados para series de tiempo por su alta potencia y sencillez (Rameshwar, Shriya, Girish Rao, & Ramya, 2021). El modelo se basa en tres componentes, una parte

autoregresivo, un modelo de media móvil y una diferenciación integrada, esto combina para obtener una tendencia, estacionalidad y otros patrones que impactan una serie de tiempo (Arévalo, 2022)

AR: p = orden de la parte autorregresiva
I: d = grado de la primera diferenciación
MA: q = orden de la parte de medias móviles

2.1.9 Modelos de Machine Learning (ML)

El machine learning es una de las ramas de la inteligencia artificial que ha cobrado gran relevancia en la ciencia de datos a partir de la revolución de internet dado que se dispone de gran cantidad de datos, los cuales son usados para que los algoritmos se entrenen y aprendan sobre estos y tengan la capacidad de hacer predicciones, clasificaciones, clustering, detección de anomalías, reducción de dimensionalidad, recomendación, procesamiento de lenguaje natural, entre otros. (Sebastian Raschka, 2022).

Existen tres diferentes tipos de machine learning que se derivan básicamente del tipo de datos usados para entrenar los algoritmos, estos son el aprendizaje supervisado, no supervisado y el aprendizaje por refuerzo. En el presente documentos usaremos modelos con aprendizaje supervisado con el objetivo de predecir nuestra variable objetivo.

Continuando con la definición de (Sebastian Raschka, 2022) “El objetivo principal del aprendizaje supervisado es aprender un modelo a partir de datos de entrenamiento etiquetados que nos permita hacer predicciones sobre datos no vistos o futuros. Aquí, el término "supervisado" se refiere a un conjunto de entrenamiento ejemplos (entradas de datos)

donde las señales de salida deseadas (etiquetas) ya son conocidas. Aprendizaje supervisado es entonces el proceso de modelado de la relación entre las entradas de datos y las etiquetas".

Estos mismos autores han documentado un flujo de trabajo típico para los modelos de machine learning enfocados a predicción. A continuación, se muestra la ilustración realizada por los autores (Sebastian Raschka, 2022):

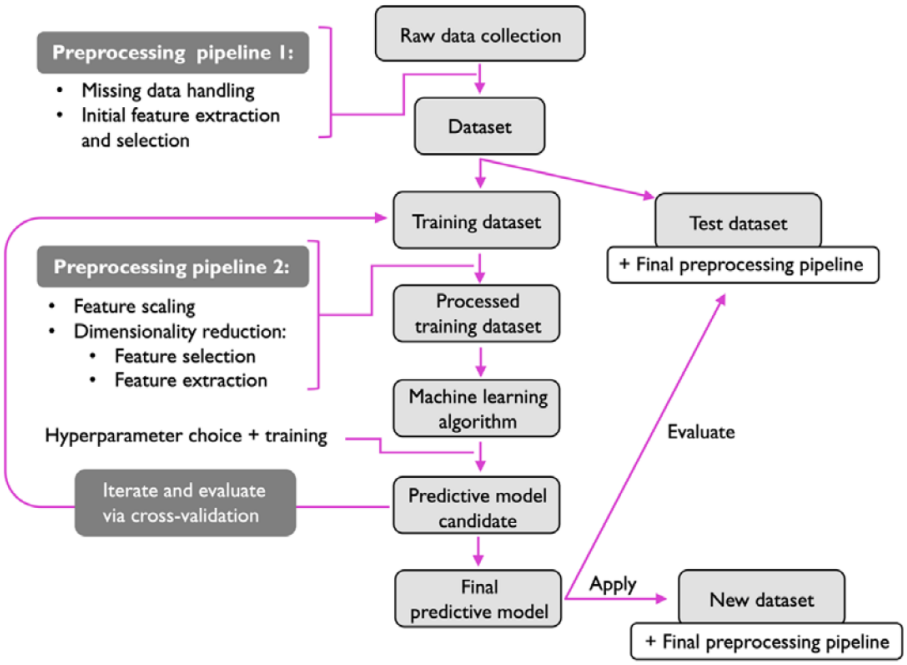

Ilustración 1 "Flujo de trabajo para modelos de Machine Learning"

2.1.10 Métricas

Las métricas de evaluación son parámetros utilizados para estimar o determinar la precisión de los modelos usados para la predicción de las series de tiempo, usualmente se realiza para

comparar cuál de los modelos tiene el mejor resultado en cada parámetro, Las métricas que se usaran en el estudio son las siguientes:

- **Error cuadrático medio**

El MSE es una medida de la diferencia entre los valores reales y los valores pronosticados. Se calcula tomando la media de las diferencias al cuadrado entre los valores pronosticados y los valores reales. (Rob J & Anne B, 2006)

- **Error medio absoluto**

El MAE es similar al MSE, pero en lugar de tomar la media de las diferencias al cuadrado, toma la media de las diferencias absolutas entre los valores pronosticados y los valores reales. (Rob J & Anne B, 2006)

- **Raíz del error cuadrático medio**

El RMSE es una medida del error de predicción que se expresa en las mismas unidades que los datos originales. Se calcula tomando la raíz cuadrada del MSE. (Rob J & Anne B, 2006)

2.2 Estado del arte

El primer criterio de búsqueda a través de la plataforma Google Scholar y Biblioteca Icesi fue la aplicación de modelos tradicionales de Forecasting, modelo ARIMA o algún modelo predictivo. El segundo criterio fue la relación con el negocio, en este caso enfocado a producto financiero, y finalmente relación con la parte operacional interna, en líneas de producción, o enfocado a capacidad operacional. Por no ser restrictivo no se establece límite de fecha.

Cabe resaltar que no se encontró ningún documento similar al del proyecto actual. Se encontraron varios métodos de abordar los riesgos financieros y la segmentación de clientes a partir de modelos predictivos en el sector Bancario. Sin embargo, se encontraron investigaciones enfocadas a pronosticar la demanda, como:

- (Bishal, Bidesh, Subir, & Taha Selim, 2022), Este estudio tiene como objetivo pronosticar la demanda de etanol en India hasta 2030, en el estudio desarrollaron modelos de regresión y modelos ARIMA para pronosticar la demanda de gasolina de acuerdo con los datos históricos. Como hallazgo entre todos los modelos de regresión usados (Lineal, exponencial, logaritmo, inverso, cuadrático, etc.), el modelo ARIMA tuvo el mejor desempeño evaluado por el error más bajo.

- (Guillermo, Alejandra, Juan Carlos, & Claudia,, 2009), Este estudio se basa en el análisis de las series temporales en el pronóstico de la demanda para un producto como resultado descartan la metodología ARIMA pues es compleja respecto de las otras analizadas, y sus resultados no fueron los esperados debido al fuerte componente estacional que tienen los datos reales, así como también su falta de estacionariedad. Finalmente, concluyen que el suavizado exponencial logro mejores resultados para su modelo.

Por otro lado, se encontró una investigación que combina la optimización de personal y predicción de demanda de servicios enfocada en el área hospitalaria. Puntualmente el problema que buscaban resolver los autores (Xuan, 2020) era optimizar el personal hospitalario basado en la predicción de pacientes que podían llegar al hospital. Para solucionar el problema propusieron un modelo de optimización en dos pasos, donde el

primero era un modelo predictivo (Prophet – Random Forest) de la cantidad de pacientes que tenía como entrada el número de pacientes, los tipos de enfermedades y una serie de tiempo del clima. El resultado de este modelo se usó como entrada para un segundo de optimización (MILP de dos capas) que, sumado al personal hospitalario contratado, generaba como salida un cronograma para el personal.

Dada a la investigación anterior, se puede observar que existen trabajos similares, sin embargo, ninguno abarca los 3 enfoques del proyecto actual de Análisis de capacidad a partir de modelos predictivos en el sector bancario.

3. METODOLOGÍA

3.1 Esquema de trabajo

La metodología implementada es CRISP DM por sus siglas en ingles de Cross-Industry Standard Process for Data Mining, esta fue creada por IBM y es ampliamente usada en la industria para abordar proyectos de minería de datos ya que sus fases son muy coherentes con un proyecto de analítica.

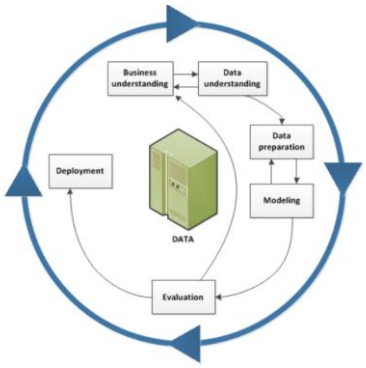

Ilustración 2 Conceptos básicos de ayuda de CRISP-DM

Fuente: IBM

3.2 Fases del Proyecto

A continuación, se presenta una descripción breve del objetivo de cada fase que se desarrolla en el proyecto de acuerdo con la metodología CRISP-DM

3.2.1 Fase 1: Comprensión del negocio

La fase inicial del proyecto tiene como objetivo conocer el requerimiento, necesidades y objetivo desde el punto de vista del área de negocio, con el fin de compartir con ellos el problema a abordar y desarrollar un roadmap de abordaje para lograr el proyecto.

3.2.2 Fase 2: Comprensión de los datos

Para el entendimiento de los datos, es importante conocer el negocio y como tal un diccionario de las variables de los datos que nos van a entregar, posterior una revisión de la calidad de los datos y exploración para evaluar relevancia de los datos.

3.2.3 Fase 3: Preparación de los datos

En este punto la idea es trabajar con los datos suministrados por la empresa, realizar transformaciones necesarias, selección o eliminación de variables y limpieza de datos, con el fin de dejar los datos listos para la construcción de los modelos predictivos.

3.2.4 Fase 4: Modelado

Durante la etapa de modelamiento se seleccionarán modelos tradicionales estadísticos como ARIMA, comparado con modelos predictivos para evaluar la predicción.

3.2.5 Fase 5: Evaluación

En la fase de evaluación del modelo se definen los criterios de éxito del modelo para negocio, y las métricas para calificar el modelo analíticamente que tan bueno o malo es. Se revisa a nivel general el proceso realizado si se debe realizar una mejora a nivel de negocio o modelo predictivo para seguir a la siguiente fase.

3.2.6 Fase 6: Despliegue

Para la fase final el objetivo es implementar un tablero de control en Power BI para que el área de negocio pueda realizar seguimiento del modelo diario de predicción de capacidad y número de solicitudes esperadas al día.

Fase CRISP-DM	Objetivo asociado	Tareas
Entendimiento del Negocio	Objetivo 1: Identificar modelos de serie de tiempo para la variable demanda de solicitudes de desembolso para pronosticar su comportamiento.	Determinar objetivo del negocio Evaluar situación actual
Entendimiento de los datos		Recolección de datos Exploración de datos Verificar calidad de datos
Preparación de los datos		Selección de datos Limpieza de datos Transformación de datos
Modelado		Selección modelos a implementar Construir modelos Evaluar modelos
Evaluación	Objetivo 2 y 3: Identificar y evaluar los modelos a través de métricas que permitan establecer el mejor pronóstico de la variable objetivo. Calcular cantidad de personas necesarias para atender la demanda pronosticada de solicitudes de desembolsos de acuerdo con métrica estándar.	Evaluar los resultados Revisión del proceso
Despliegue	Objetivo 4: Realizar una visualización en Power Bi del pronóstico de demanda y la cantidad de personas requeridas.	Tablero de visualización

Tabla 1 Fases y objetivos asociados según CRISP-DM
Fuente: Elaboración propia

4. DESARROLLO

4.1 Entendimiento del negocio

De acuerdo con lo dicho previamente en el contexto y planteamiento del problema, para la gerencia del área es importante contar con una medición que le permita conocer la productividad del equipo que atiende las solicitudes de desembolso de las libranzas. Para entender el proceso en su globalidad y como parte del entendimiento del flujo que debe seguir una solicitud desde que llega al banco hasta que se realiza el desembolso, se presenta la siguiente ilustración:

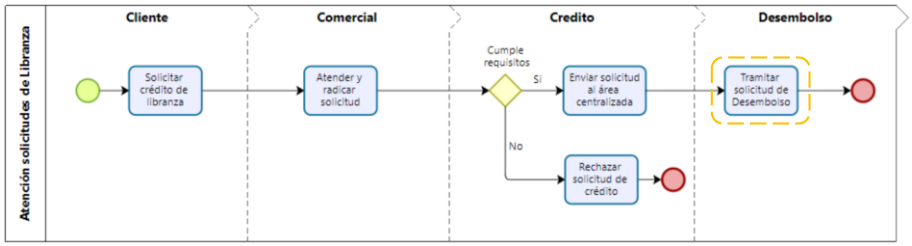

Ilustración 3 Diagrama de flujo del proceso
Fuente: Elaboración propia

El análisis del problema planteado se centra en el nodo "tramitar solicitud de desembolso" de acuerdo con diagrama anterior y que de acuerdo con normativa de experiencia al cliente que ha establecido la organización, el desembolso debe realizarse máximo en el tercer día hábil después de recibida la solicitud. Es en este nodo donde se presenta la diferencia en la medición de la productividad resultante del sistema transaccional versus el informe de elaboración propia del área.

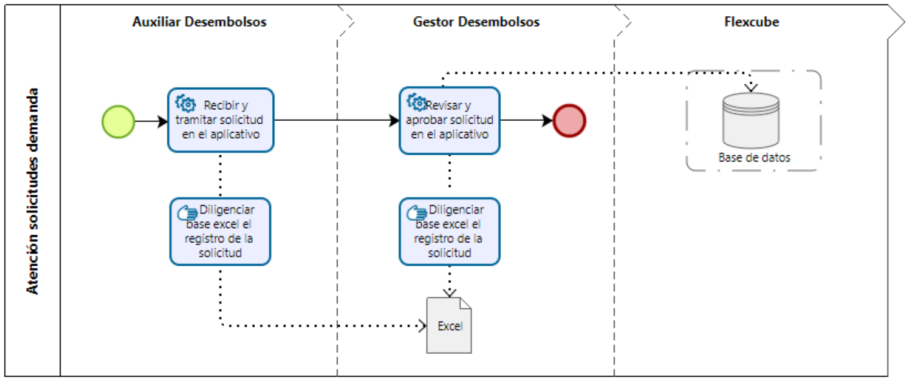

Ilustración 4 "Flujo general del proceso de desembolso"

La ilustración 4 es el zoom in de la ilustración 3, donde se explica de manera general el comportamiento del negocio, el auxiliar de desembolso recibe las solicitudes, el gestor las revisa y las atiende, mientras se alimenta la base manual de Excel, y en paralelo por debajo del aplicativo va recolectando la información en la base de datos, diferencia donde radica el problema de este documento.

4.2 Recolección y Entendimiento de los datos

La principal fuente de datos es una base transaccional que contiene toda la información de créditos de los clientes, sobre esta se ejecutó un código SQL para extraer de las tablas los registros desde el año 2020 y lo corrido del año 2023 (abril) de los Clientes que solicitaron el producto de Libranza. Luego de la entrega de los datos, por parte del área de tecnología dla organización, se realizó la limpieza y preparación de estos con el objetivo de tener una base depurada y apta para los modelos que se van a aplicar de Series de Tiempo. Los datos recibidos componían una base de datos inicial que contaba con 32 variables, sobre las cuales se le realizó un proceso de limpieza con el apoyo de área experta para descartar variables que

no eran necesarias para el estudio y que no aportaban información relevante para la gerencia, finalmente se seleccionaron 12 variables que se muestran en la siguiente tabla:

VARIABLE	*DESCRIPCIÓN*	*TIPO DE DATO*
CODIGO_PRODUCTO	Indica el tipo de producto de colocación	String
FECHA_DESEMBOLSO	Fecha en la cual se realiza el giro de los recursos al cliente	Date dd/mm/yyyy
VALOR_DESEMBOLSADO	Cantidad en pesos COP girado al cliente	Double
VALOR_APROBADO	Cantidad en pesos COP aprobado para el producto de colocación	Int
CODIGO_OFICINA	Código asociado a la oficina donde se radica la solicitud del producto	Int
REGIONAL_RADICACION	Nombre de la región colombiana donde está ubicada la oficina de radicación del producto	String
CANAL_VENTA	Nombre de la fuerza de ventas asociada a la venta del producto	String
FECHA_APROBACION_CREDITO	Fecha en la cual se aprobó un valor en pesos COP para el producto de colocación	Date dd/mm/yyyy
EJECUTIVO_VENTAS	Nombre del vendedor que realiza la venta del producto	String
CODIGO_HOST	Código asociado a los ejecutivos de venta que ponen el producto	String
TASA_NOMINAL	Tasa de interés nominal anual que se cobra por el crédito	Double
FECHA_RADICACION	Fecha en la cual se radicó la solicitud para giro en el área de desembolsos	timestamp dd/mm/yyyy HH:MM

Tabla 2 "Diccionario de datos"
Fuente: Elaboración propia

La base depurada contiene 144.538 registros que representan un volumen de datos que se puede gestionar con las herramientas disponibles en un solo pc. Por otro lado, se procedió a crear una variable llamada "DEMANDA" que se calculó a partir de la variable "FECHA_RADICACION" que es de tipo timestamp. Lo anterior se realiza con el fin de calcular la cantidad de solicitudes que llegan por día al área de desembolsos. Con esta nueva variable el dataset se reduce de 144.538 registros a 731 que contienen el recuento de las incidencias de las solicitudes de desembolso diariamente, en la ilustración 5 se muestra el comportamiento a través del tiempo de la variable objetivo "DEMANDA".

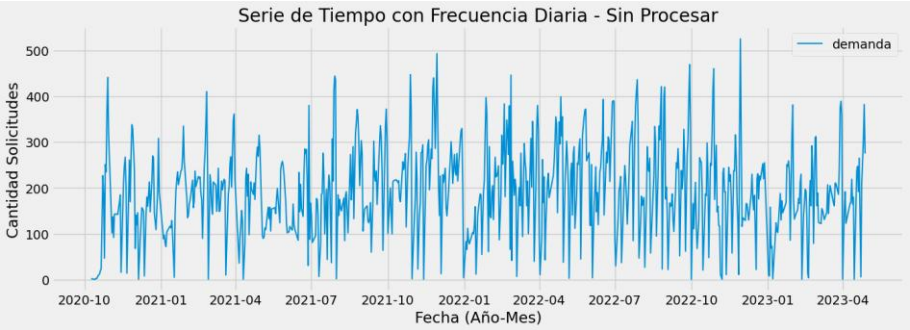

Ilustración 5 "Serie de Tiempo con Frecuencia Diaria – Sin Procesar "

Fuente: Elaboración propia

La serie mostrada en la ilustración 5 se ha denominado como "Serie de Tiempo con Frecuencia Diaria – Sin Procesar", dado que representa los datos sin realizar ningún tipo de ajuste o imputación. Sobre la serie se pudo observar que contenía datos de lunes a domingo, sin embargo, el sábado y el domingo son días catalogados en la organización como no laborales y normalmente no se programan personas para atender solicitudes este día. Los siguientes son los datos descriptivos de esta serie con la variable demanda:

	Sin Procesar
	Demanda
Recuento	731
Media	197
STD	98,89
Mínimo	1
25%	137
Mediana	194
75%	258
Máximo	525

Además, con la variable "FECHA_DESEMBOLSO" se pudo obtener la cantidad de desembolsos realizados a los clientes dla organización. Como se observa en la ilustración 6, esta cantidad fluctúa entre 2.100 y 6.100 solicitudes por mes durante el periodo de estudio, que inicia en Octubre 2020 y termina en Abril 2023. Cabe mencionar que se puede ver un decrecimiento a finales del año 2020 e inicios 2021, producto de la pandemia. Este comportamiento en la serie puede generar algún impacto en el momento de la evaluación de modelos, por lo cual se tendrá a consideración más adelante en este documento. De igualmente manera también se resalta de la ilustración su comportamiento descendente en los meses de Enero de todos los años.

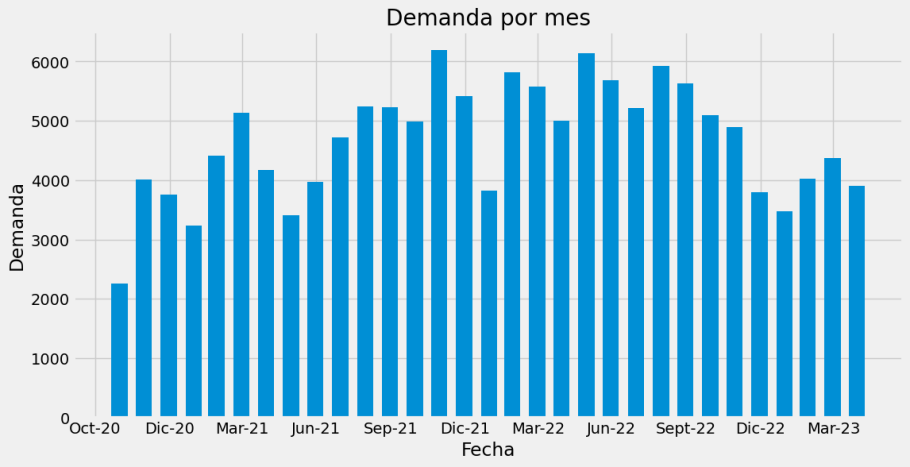

Ilustración 6 "Distribución de la cantidad de solicitudes de desembolso"

De igual manera, se evidencia en el consolidado que los meses durante los cuales se presentan mayores desembolsos son Marzo y Noviembre, lo cual representa una particularidades del producto y del mercado.

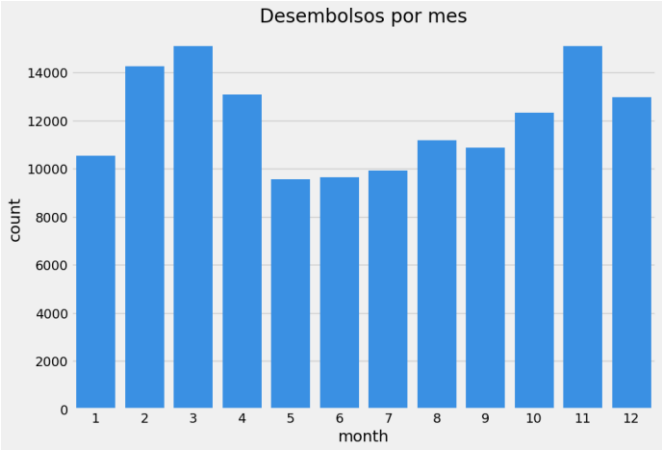

Ilustración 7 "Distribución mensual de solicitudes de desembolso"

De igual forma se realizó un análisis descriptivo de variables que para el negocio tienen importancia. En la siguiente ilustración se destaca la distribución de las regionales de radicación, la cual presenta una distribución similar entre las cuatro zonas donde los comerciales venden libranzas.

	REGIONAL_RADICACION	frequency	percentage	cumulative_perc
0	REGIONAL SUROCCIDENTAL	50865	0.351914	0.351914
1	REGIONAL NORTE	33910	0.234610	0.586524
2	REGIONAL NOROCCIDENTAL	31194	0.215819	0.802343
3	REGIONAL BOGOTA	28569	0.197657	1.000000

Ilustración 8 "Frecuencia de la variable Regional Radicación"

Se destaca que el principal canal de ventas es “Fuerza de Ventas Libranzas”, con una participación aproximada del 76%, seguido de "Outsourcing” con un 18%, y el restante en otras fuerzas comerciales.

	CANAL_VENTA	frequency	percentage	cumulative_perc
0	Fuerza de Ventas Libranzas	110119	0.761869	0.774079
1	Outsourcing	25862	0.178929	0.955876
2	Outsourcing Libranza	2127	0.014716	0.970828
3	Oficinas Banca Personas	1825	0.012626	0.983656
4	Televentas	1346	0.009312	0.993118
5	Fuerza de Ventas	875	0.006054	0.999269
6	Vendors Libranza	99	0.000685	0.999965
7	Division Comercial	5	0.000035	1.000000

Ilustración 9 “Frecuencia de la variable CANAL_VENTA”

Alineado al contexto sobre la importancia de la medición de la productividad para el área, en la siguiente ilustración podemos evidenciar cuanto están tardando entre la radicación y el desembolso. Se puede observar que aproximadamente el 84% cumple con las políticas de experiencia, cumpliendo con los desembolsos hasta en 3 días hábiles. Sin embargo, se evidencia que el 15% de los desembolsos tardan más de 3 días, lo que va en contra de las políticas actuales dla organización y que podría impactar al negocio. Como dato atípico, un valor negativo es decir que la fecha del desembolso fue antes de la fecha de radicación, lo que sería imposible, sin embargo, puede ser algún problema del sistema.

	categoria	frequency	percentage	cumulative_perc
0	Mismo día	58297	0.403333	0.403333
1	1 día	46364	0.320774	0.724107
2	3 días	17787	0.123061	0.847168
3	2 días	10610	0.073406	0.920575
4	3-5 días	8927	0.061762	0.982337
5	Mayor 5 días	2552	0.017656	0.999993
6	Negativo	1	0.000007	1.000000

Ilustración 10 "Frecuencia de la diferencia de días entre Fecha radicación y Fecha desembolso"

Dada la validación de días que tarda la radicación del desembolso al desembolso del dinero, se muestra en la ilustración las dos series en paralelo, para evidenciar el desfase temporal que existe. Vemos que se comportan muy similar a pesar del desfase de tiempo que existe, es consistente dado que casi el 80% se desembolsa en menos de tres días.

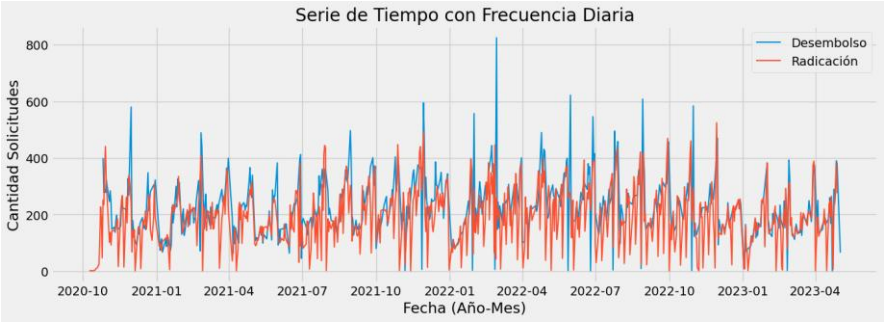

Ilustración 11 "Serie de tiempo Radicación vs Serie de tiempo Desembolso"

Para corroborar el desfase temporal de las dos series, se muestran a continuación la ilustración con la serie de radicación previa una semana para ver el efecto cuanto se radica vs cuanto se desembolsa.

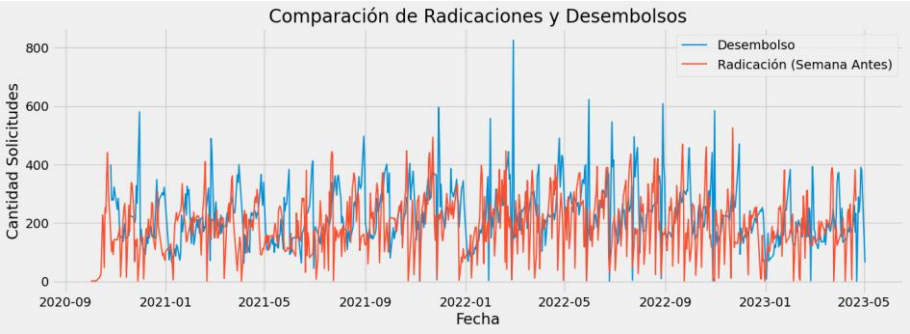

Ilustración 12 "Comparación temporal series de tiempo"

4.3 Preparación de los datos

Con el fin de que algunos modelos tuvieran los inputs requeridos y que la serie se ajustara lo mejor posible a la realidad de la dinámica del negocio, se procedió a estructurar los datos en tres series de tiempo de la siguiente manera:

- **Inicial (1):** Se definió con el método asfreq una frecuencia diaria "D", el cual completa la serie de tiempo con todos los días e imputa los valores con cero.
- **5 Días (2):** Dado que se tenían datos en los días sábado y domingo, y que realmente esos eran datos atípicos en esos días, se procedió a sumar las radicaciones realizadas esos días al siguiente lunes. Después con el método asfreq se definió una frecuencia diaria de días laborales "B", el cual deja la serie con datos lunes a viernes.

- **Semanal (3):** Se creó una serie con el método resample "W", el cual deja la serie con una frecuencia semanal de lunes a domingo.

La siguiente Tabla 3 muestra los datos descriptivos de cada una de las series mencionadas en el punto anterior:

	Series de tiempo		
	Inicial	**5 Días**	**Semanal**
	Demanda		
Recuento	932	666	134
Media	155,08	217	1078,64
STD	119,53	111,98	398
Mínimo	0	0	2
25%	11	149	841
Mediana	165	210	1070,5
75%	238	276,75	1326
Máximo	525	779	2062

Tabla 3 "Resumen descripción de los datos"

Las tres estructuras de la serie de tiempo son las que se van a evaluar con los diferentes modelos, sin embargo, las ilustraciones que se mostraran en adelante corresponderán a la estructura y el modelo que mejor resultado haya tenido. Adicional, se realizó estandarización de los datos para tener ajustada la serie a los diferente requerimientos de los modelos.

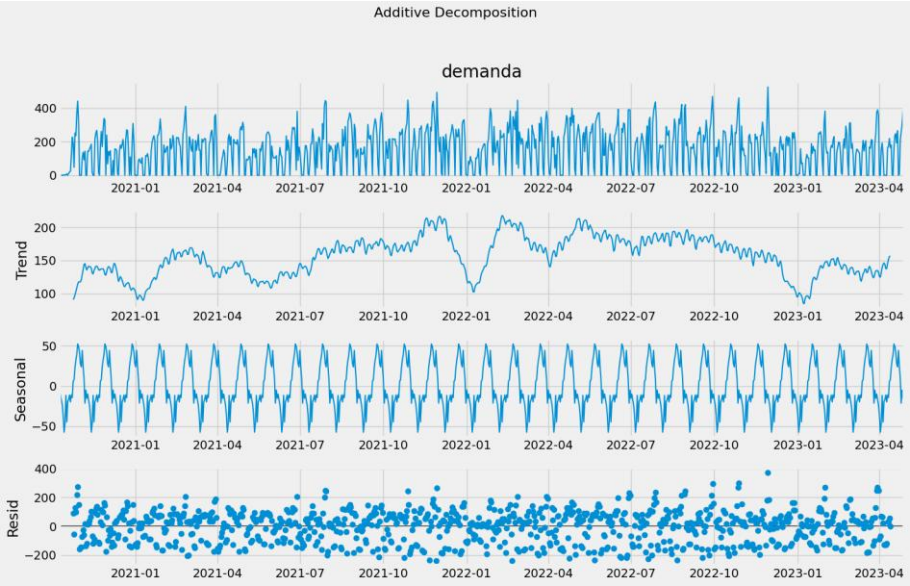

Ilustración 13 "Descomposición de la serie de tiempo"
Fuente: Elaboración propia

La ilustración 7 se puede observar el comportamiento de la serie de tiempo, en su componente general se pueden ver algunos unos picos que alcanzan las 400 solicitudes por día. En el mes de enero se puede ver como decrece la cantidad de solicitudes diarias.

Si analizamos el componente de tendencia, podemos concluir que no existe una tendencia clara en los datos, por lo que se podría decir que es estable. Sin embargo, si se puede evidenciar que los meses de enero han presentado un patrón a la baja y a partir de febrero se incrementan al nivel estable. Si analizamos el comportamiento de la tendencia solo del año 2021, podríamos decir que es una tendencia al alza, pero si analizamos solo la del año 2022 la tendencia es a la baja y en lo corrido de año 2023 se podría que decir que la tendencia es estable.

En su componente estacional, claramente se ve en el gráfico que la serie se comporta estacionalmente y se se encuentra en la variación del rango -50 a 50.

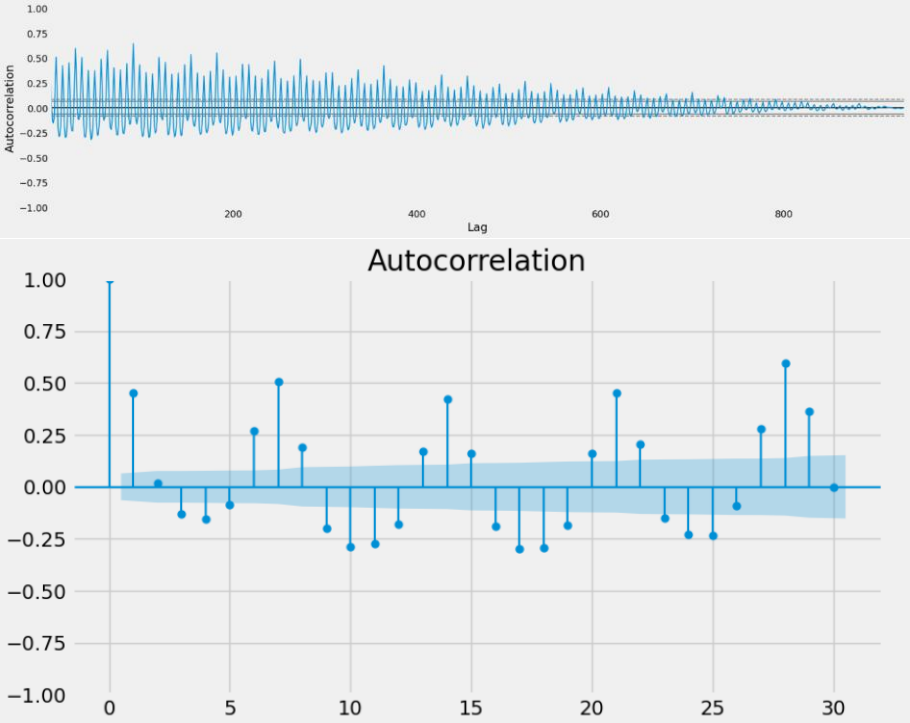

Ilustración 14 "Gráfico de Autocorrelación para la serie de tiempo"

Del grafico de autocorrelación se valida el comportamiento de la serie de tiempo, donde vemos que en la que tiene lags = 800, dado que tenemos una serie completa de aproximadamente 2.5 años, vemos que tiende a 0, lo que dice que la magnitud de la correlación a través de los lags se elimina, además que en la gráfica inferior vemos que los rezagos más importantes que nos darían una correlación se repiten cada 10 lags.

Adicionalmente se realizó la prueba Dickey-Fuller para comprobar la serie es estacionaria o no, el resultado de la prueba indica que el valor del estadístico de prueba ADF es -5.6988. Este valor es menor que los valores críticos correspondientes para los niveles de significancia del 1%, 5% y 10%, lo que indica que la serie es estacionaria con un alto grado de confianza.

Además, el valor p de la prueba es muy pequeño (0.000001), lo que indica que la probabilidad de obtener un valor de estadístico de prueba tan extremo como el observada es muy baja. Por lo tanto, se rechaza la hipótesis nula de que la serie tiene raíz unitaria y se concluye que la serie es estacionaria.

```
ADF Statistic: -5.698819
p-value: 0.000001
Critical Values:
        1%: -3.438
        5%: -2.865
        10%: -2.568
```

Tabla 4 "Resultado prueba ADF"

4.4 Modelado

Con la meta de alcanzar el objetivo de este documento, se seleccionaron unos modelos predictivos basados en una configuración de datos univariados y multivariados que se presentan en la tabla 5.

Modelo	Periodo datos	Modelos	Horizonte	Train	Test	Pred
Regresivo con media móvil Lasso con transformación Regresivo lineal Promedio móvil Suavización exponencial Holt Winters ARIMA Profeta Machine Learning	Octubre 2020-Abril 2023	Inicial	2 meses	872	60	60 días
		5 días	2 meses	606	60	60 días
		Semanal	12 semanas	122	12	12 semanas

Tabla 5 "Configuración de los datos para la evaluación de modelos"

4.5 Evaluación de los modelos

Para cada uno de los modelos evaluados a continuación se ha realizado la partición del dataset en dos partes llamadas train y test, los cuales serán usados para el entrenamiento y validación del pronóstico que está dando como resultado el respectivo modelo. Además, los datos se han estandarizado a través de StandardScaler.

4.5.1 Modelos Estadísticos

4.5.1.1 Media móvil

De las tres transformaciones de las series de tiempo la mejor que se obtuvo para el modelo estadístico-media móvil fue para la serie semanal con un resultado del MSE= 0,4991. Se

atribuye el mejor resultado ya que es la serie que está consolidando datos semanales y esto elimina las tendencias diarias que tienen los datos.

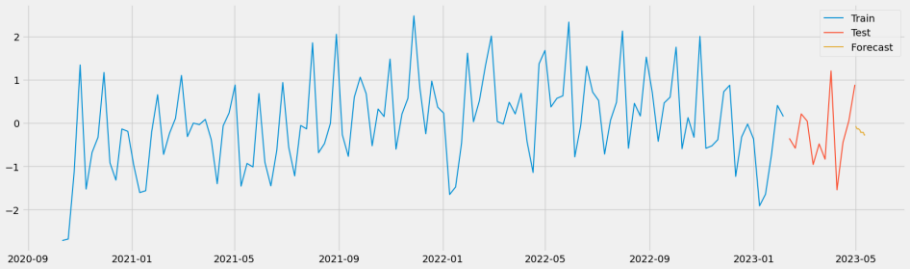

Ilustración 15 "Gráfico para el modelo media móvil con MSE = 0,4991"

Se puede observar en la ilustración que el modelo media móvil no fue ideal, y se vea afectado por la cantidad de datos la cual en la línea amarilla no logra verse la tendencia, sin embargo, los pocos datos que se tienen en semanas no permitieron ampliar el pronóstico por el margen de error. Además, posiblemente por la limitación de este en la captura de los patrones de los datos, y dado que estos no tienen un comportamiento lineal sino como se visualizó anteriormente es estacionario, cabe aclarar que la elección de la ventana de tiempo se realizó con varias opciones, sin embargo, es un modelo estático el cual no se mejoran los parámetros o las ventanas para la predicción. Lo mismo ocurrió para las configuraciones inicial y 5 días, porque estas tienen aún más marcados los patrones de estacionalidad que el modelo de promedio no logra adaptarse.

4.5.1.2 Suavización exponencial simple

Al igual que el modelo anterior, para este la mejor configuración fue la serie semanal. Como se observa en la ilustración la línea amarilla de la predicción no tiene ni la tendencia de los datos, ni la apertura de esta, es similar a una línea recta, lo que significa así el error sea tan

solo de la mitad, que el modelo no alcanza a capturar la tendencia, patrones y variaciones de los datos.

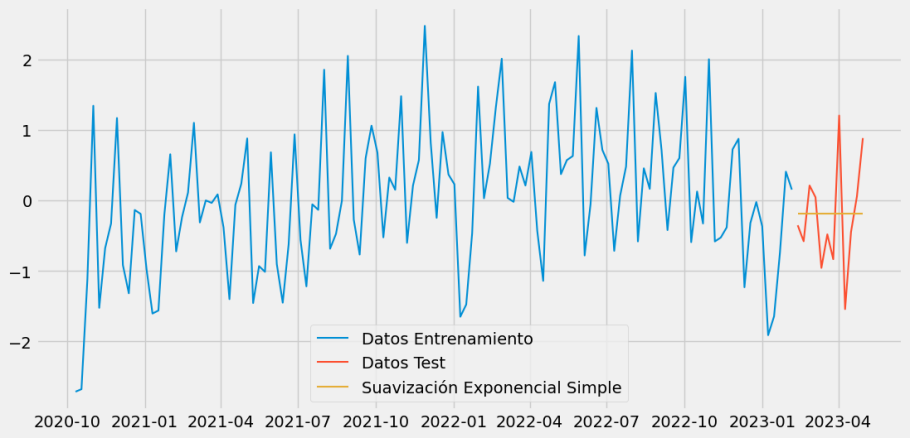

Ilustración 16 "Gráfica Suavización exponencial Simple MSE = 0.546"

Atribuimos este resultado a que es un modelo simple, donde se toma el promedio de los datos y al tener una variación en los datos el modelo no tiene el ajuste que se necesita para esta ni las demás configuraciones de las series.

4.5.1.3 Suavización Exponencial Lineal de Winters (Holt-Winters)

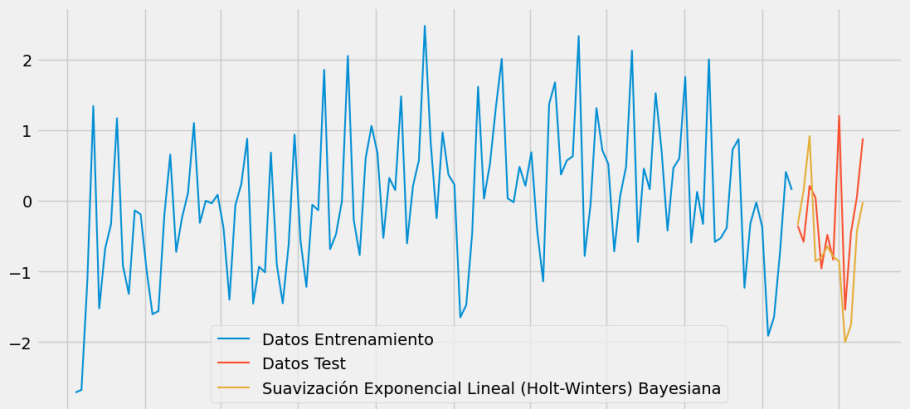

Ilustración 17 "Gráfica Suavización Holt-Winters MSE = 0,563"

Para el modelo de suavización con Holt-Winters el mejor resultado lo obtuvo la configuración de serie semanal, se destaca este modelo puesto que ayuda a descomponer series de tiempo con los componentes estacionales y dado el comportamiento de los datos y de un posible futuro con los mismos patrones de salida, logra ajustarse mas al modelo. Sin embargo, cabe destacar que la predicción de los datos y los datos en crudo tienen tendencia crecientes y decrecientes por lo que es importante para el negocio que cuando la demanda este alta pueda predecir un valor alto para estar preparados en la atención de desembolsos, pero evidenciamos que en el pico más alto la predicción ha sido baja, esto se le atribuye al modelo de promedio adaptado y suavizado con los datos anteriores, lo que causa que si hubo una baja demanda en la semana anterior tienda a predecir un valor bajo.

4.5.1.4 Arima

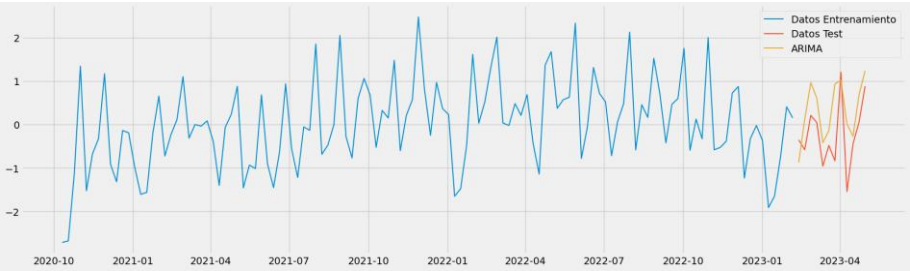

Ilustración 18 "Gráfica ARIMA resultado MSE=0.535"

El modelo de Arima, para las configuraciones diarias no fue bueno ni acertado con unos valores cercanos de MSE al 0.88, y una representación visual de una línea recta alejada del patrón de los datos, indica que este modelo de series de tiempo no se alinea bien a cualquier tipo de dato. La ilustración 12 corresponde ARIMA con series de tiempo semanales, donde se obtuvo los mejores hiper parámetros (4,1,3), que implica que tiene un componente autorregresivo de orden 4, es decir, que posiblemente la serie de tiempo está relacionada cuatro semanas hacia atrás y estos valores influir en el valor futuro. El siguiente componente de integración I=1, el número de veces de diferenciaciones que necesita la serie para ser estacionaria. Y finalmente el componente de media móvil MA=3 indica que tiene relación con 3 errores residuales de las observaciones anteriores, lo que podría afectar el modelo puesto que estaría auto correlacionado.

4.5.2 Modelo de Machine Learning Autoregresivo Univariado y con Dos Variables Externas

Para la evaluación de modelos de machine learning se ha tomado como referencia el notebook llamado “Skforecast: forecasting series temporales con Python y Scikit-learn” (Ortiz, 2023) donde se implementa o adaptan funciones de regresión de la librería Scikit-learn.

4.5.2.1 Modelo Forecaster Autoregresivo con Random Forest como regresor

Este modelo de Machine Learning tiene buenos resultados para las tres configuraciones definidas en este trabajo, para la serie diaria inicial un resultado del error del 0,25, la serie de 5 días semanales un error del 0,279 y el mejor resultado lo obtiene la serie semanal con un error del 0,22, para el cual se configuro con 100 lags, donde este parámetro es la cantidad de observaciones hacia atrás que el modelo usara como predictores y los steps = 12 son la cantidad de predicciones que realiza el modelo, en este modelo específicamente se tienen en cuenta las predicciones para entrenar el modelo, esto quiere decir que la primera predicción es usada para calcular la segunda y así sucesivamente hasta completar la cantidad de steps parametrizados.

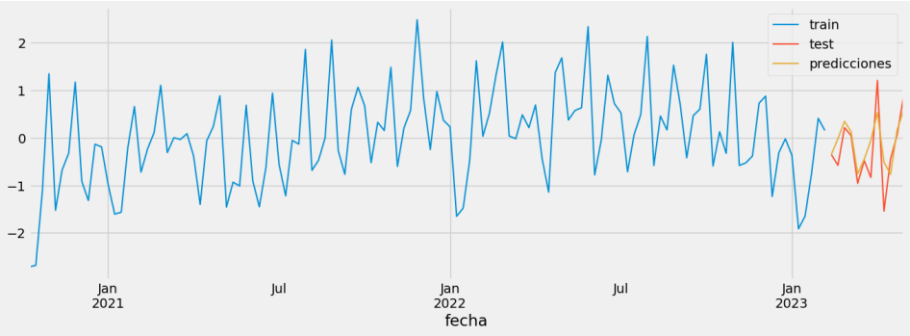

Ilustración 19 "Gráfica Forecaster Autoregresivo con Random Forest resultado MSE=0.224"

4.5.2.2 Modelo Forecaster Autoregresivo con Random Forest como regresor y Variable Exógena

En este modelo se incluye la variable exógena IBR, dado que se busca explorar el comportamiento del modelo con una variable correlacionada inversamente.

En siguiente gráfico se puede ver la variable objetivo y la variable IBR. También se incluye el IPC, pero no se consideró para evaluar el modelo.

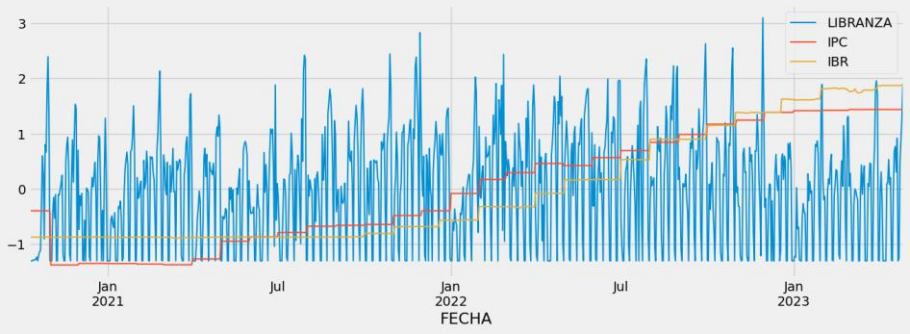

Ilustración 20 "Gráfica Serie de tiempo Libranza, IPC e IBR"

Como resultado con la variable exógena se obtiene el siguiente resultado:

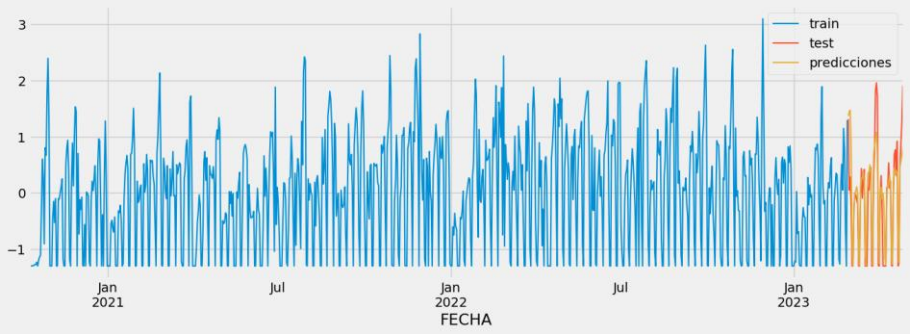

Ilustración 21 "Gráfica Forecaster Autoregresivo con Random Forest + exógeno resultado MSE=0.2641"

A pesar de incluirse en el modelo una variable exógena que podría llegar a aportar información al modelo para realizar una mejor predicción, no se obtiene una mejora sustancial en el modelo.

4.5.2.3 Modelo Forecaster Autoregresivo Directo con Lasso como regresor

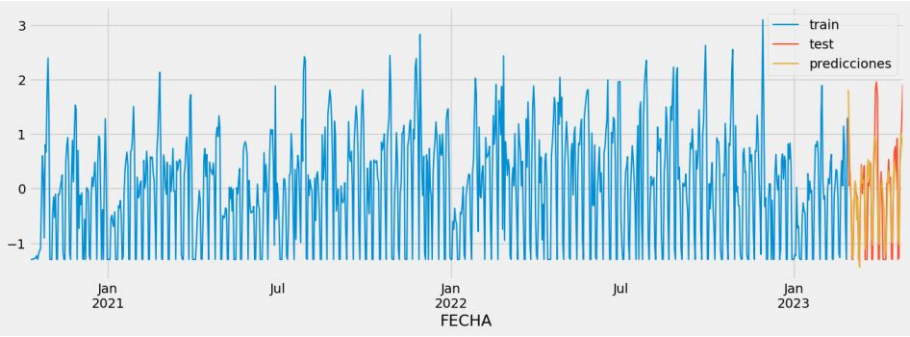

Ilustración 22 "Gráfica Forecaster Autoregresivo Directo con Lasso resultado MSE=0.2934"

Este modelo utiliza como regresor un modelo lineal con penalización de Lasso, sin embargo, el resultado del MSE no es mejor que otros modelos.

4.5.2.4 Modelo LSTM

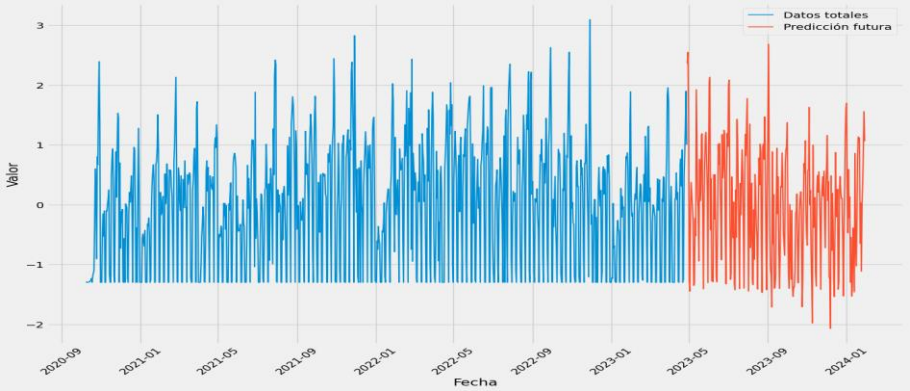

Ilustración 23"Gráfica LSTM con MSE = 0.46"

El modelo LSTM es un modelo de red neuronal que en este caso contempla una sola capa densa, 50 neuronas que pasan a la capa, utilizando datos supervisados parametrizados con los 12 valores anteriores para predecir el siguiente valor de salida, por lo que se puede evidenciar en la ilustración el modelo de redes neuronales, es un modelo aparentemente bueno para vincular los patrones que tienen los datos, y es capaz de aprender esos patrones complejos y la no linealidad de la serie de tiempo.

4.5.2.5 Modelo Profeta

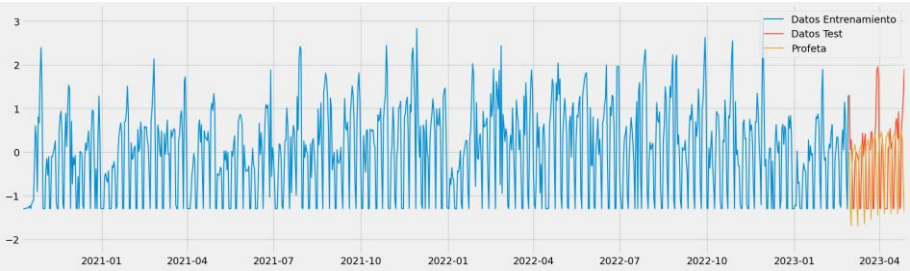

Ilustración 24"Gráfica modelo Profeta con MSE = 0.433"

El modelo profeta obtuvo su mejor resultado en la configuración diaria, es probable que el modelo semanal al no tener tantos datos, este no tuviera un mejor rendimiento, dado que es un modelo que necesita muchos datos históricos para poder capturar las fluctuaciones y el comportamiento de los datos para dar buenos resultados en su pronóstico. Para la serie de tiempo diaria, se observa que el modelo es muy cercano a los datos de entrenamiento por lo que al obtener una predicción estaremos cerca del valor real.

4.6 Resumen de resultados y Pronóstico con modelo seleccionado

MODELOS	*Configuración*	*REGRESOR*	*LAGS*	*STEPS*	*MSE*
Media Móvil	1	N/A	N/A	N/A	0.887
	2				0.887
	3				0.499
Suavización Exponencial Simple	1				0.910
	2				0.579
	3				0.546
Suavización Exponencial HoltWinters	1				0.886
	2				0.563
	3				0.582
ARIMA	1				0.883

	2				0.535
	3				0.682
Algoritmo Profeta	1				0.433
	2				0.876
	3				1.097
LSTM	1				2.17
	2				18.8
	3				16.88
Forecaster Autoregresivo	1	**Random Forest**	60	60	0.258
	2				0.279
	3		**100**	**12**	**0.224**
Forecaster Autoregresivo + Variable Exógena	1	Random Forest	60	60	0.264
Forecaster Autoregresivo Direct	1	Lasso	120	60	0.293
	2				0.333
	3			12	0.328

Tabla 6 Resumen Resultados Elaboración Propia

La siguiente ilustración muestra el comportamiento de la serie Real y Predicciones realizadas con el modelo que mejor MSE obtuvo en la evaluación. En total se realizó la predicción para 12 semanas a partir del 07/05/2023 hasta el 23/07/2023.

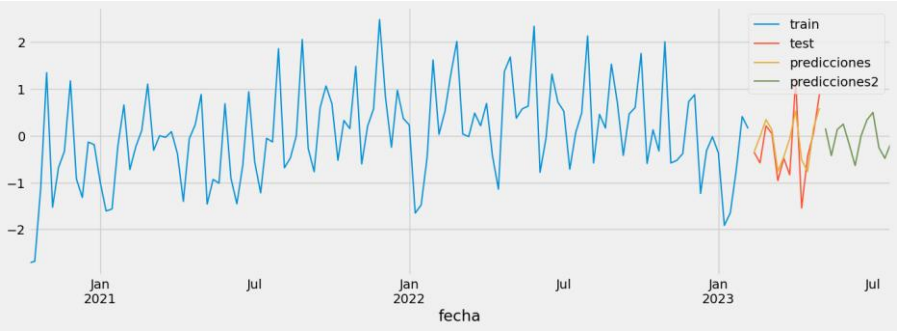

Ilustración 25" Mejor modelo"

Los siguientes son los valores obtenidos con la predicción del modelo seleccionado:

Fecha	*Predicción*
7/05/2023	1141.39
14/05/2023	910.42
21/05/2023	1131.42
28/05/2023	1176.77
4/06/2023	1007.22
11/06/2023	826.37
18/06/2023	1077.5
25/06/2023	1213.19
2/07/2023	1275.83
9/07/2023	978.48
16/07/2023	887.57
23/07/2023	1015.67

Tabla 7 " Predicción del mejor modelo"

Luego de tener la predicción del mejor modelo se realiza el calculo de la capacidad de las personas, en este caso al ser el mejor modelo una serie semanal, la formula de la capacidad de tiempo estándar dividido tiempo disponible se divide por los días hábiles en este caso 5 días como se observa en la ilustración,

```
# Multiplicar la demanda por 10 (tiempo estandar operacion) y dividir por 450 (Tiempo disponible)
libranza_desestandarizado['Calculo auxiliares'] = ((libranza_desestandarizado['PREDICCION'] * 10) / 450)/5

# Multiplicar la demanda por 4.4 (Tiempo estandar operacion) y dividir por 450 (Tiempo disponible)
libranza_desestandarizado['Calculo gestores'] = ((libranza_desestandarizado['PREDICCION'] * 4.4) / 450)/5
```

Ilustración 26 "Calculo de capacidad de personas"

4.7 Despliegue de la iniciativa

Luego de documentar los modelos probados para el problema que se quería resolver, se presentan los resultados obtenidos a los interesados del proyecto dentro dla organización, lo que se hace una entrega formal del script de Python y del modelo de visualización en Power

Bi que ayudará al área para tomar decisiones, el tablero es un MVP (Producto mínimo viable) pues es manual, para tener un modelo automático se deberá surtir en próximos pasos un desarrollo directo con la base de datos para la extracción de los datos mediante SQL, y que esos datos alimenten un modelo de machine learning en Python y posterior cargarlo en el tablero de visualización. Para la entrega de este documento y cumpliendo con el objetivo propuesto se tendrá que correr el código y descargar el CSV para cargarlo en Power Bi, sin embargo, se recomienda que a futuro se construya un modelo automático de extracción de la información para la automatización de la tarea.

Ilustración 27 "Análisis descriptivo de los datos"

La ilustración 17 se construyó con los datos históricos suministrados por la organización con un enfoque de negocio para el conocimiento de cómo están los desembolsos de libranza geográficamente, la distribución por región para conocer la participación, el promedio de día entre la radicación y el desembolso y por último como es el comportamiento de los datos históricos.

Ilustración 28 "Resumen de lo obtenido por los modelos de machine learning"

La ilustración 19 es el tablero de visualización con las fechas de los 60 días próximos de acuerdo con el día en que se corra el modelo, el valor predicho para ese día, y se calcula con los tiempos estándares que se tienen en la organización del proceso operativo para los dos cargos que ejecutan el procedimiento donde se obtienen las personas necesarias para atender la demanda predicha.

5. CONCLUSIONES Y TRABAJO FUTURO

En el presente trabajo de grado, se exploraron diferentes modelos estadísticos y de machine learning enfocados a series de tiempo, con el objetivo de pronosticar la demanda del producto "crédito de libranza" del Entidad financiera y calcular la cantidad de personas necesarias para atender dicha demanda. A partir de dicho objetivo se plantearon diversos objetivos específicos que se abordaron de la siguiente manera:

Se identificaron varios modelos para el pronóstico de la demanda de solicitudes de crédito, incluyendo tres modelos estadísticos (Media móvil, Suavización simple y Suavización Holtwinters), un modelo de series de tiempo (ARIMA), y modelos de machine learning (Forecasting autoregresivo, Forecasting autoregresivo multivariable, Forecasting autoregresivo con lasso y LSTM).

Los modelos mencionados fueron evaluados utilizando la métrica MSE para determinar cuál de ellos proporcionaba el mejor pronóstico de la variable objetivo. Además, se tuvieron en cuenta criterios como la precisión, exactitud y la capacidad de capturar patrones y tendencias de la demanda. A partir de esta evaluación, se llegó a las siguientes conclusiones:

- Los modelos tradicionales como la media móvil y la suavización exponencial presentaron limitaciones al no capturar patrones complejos, como la estacionalidad y los patrones específicos del negocio. Además, la presencia de datos atípicos, como los fines de semana con demanda cercana a cero, requería una sensibilidad especial en el modelo.
- Aunque el modelo ARIMA es ampliamente utilizado para el análisis de series de tiempo, en este estudio se observó un bajo desempeño del modelo. Se concluyó que

el ARIMA no capturaba patrones no lineales ni relaciones complejas presentes en los datos, a pesar de haber realizado las pruebas de los supuestos necesarios.

- Por otra parte, con los modelos de Machine Learning se obtuvieron mejores resultados dada su capacidad de aprendizaje y captura de patrones sobre la estructura de la serie de tiempo. A pesar de que normalmente se evalúa el costo computacional de estos modelos, en este caso particular el modelo con mejor desempeño no requiere de mucho tiempo ni GPU para ser entrenado. En la evaluación de uno de estos modelos, se incluyó la variable exógena IBR[1] con el fin de darle al modelo una variable extra que pudiera robustecer su precisión, sin embargo, el MSE no obtuvo mejoras sustanciales, dado lo cual se descartó como modelo optimo. Por otro lado, se recomienda que dado el constante avance que se presenta actualmente en el campo del Machine Learning y redes neuronales, es importante investigar constantemente el desarrollo de nuevos modelos enfocados a Series de tiempo, y evaluarlos sobre la serie de tiempo para saber si se obtienen mejores resultados.

1 "El IBR es una tasa de interés de referencia de corto plazo denominada en pesos colombianos, que refleja el precio al que los bancos están dispuestos a ofrecer o a captar recursos en el mercado monetario".

Además, se calculó la cantidad de personas necesarias para atender la demanda pronosticada con el modelo de Machine Learning, utilizando la métrica estándar que ya tiene establecida la organización. Este cálculo apunta a obtener la cantidad de personas requeridas para asegurar una atención adecuada y eficiente de las solicitudes de desembolso, y que además se cumpla con los tiempos de atención establecidos por la organización. Sin embargo, se sugiere que el cálculo puede mejorarse al considerar información adicional proporcionada por la organización, como restricciones en la programación del personal basadas en la disponibilidad u otras variables que puedan impactar en la asignación de recursos.

Finalmente, se desarrolló una visualización en Power BI que presenta de forma clara y comprensible el pronóstico de demanda generado por el modelo de Machine Learning, así como la cantidad de personas necesarias para atender dicha demanda. Esta visualización facilita la comunicación de los resultados a los directores del área de desembolsos y contribuye a una mejor toma de decisiones y optimización de los recursos disponibles.

En conclusión, a través de la evaluación de diferentes modelos estadísticos y de machine learning, este trabajo de grado logró cumplir con los objetivos planteados. Se identificó el modelo con el mejor desempeño para pronosticar la demanda de créditos de libranza, se generó un pronóstico preciso, se calculó la cantidad óptima de recursos humanos necesarios para atender la demanda y se proporcionó una visualización efectiva de los resultados en power BI. Estas contribuciones son valiosas para mejorar la planificación y la eficiencia en la asignación de recursos en el área de libranza.

6. BIBLIOGRAFÍA

Arévalo, N. M. (13 de 06 de 2022). *La banca tradicional cede espacio y neobancos ahora tienen 25 millones de usuarios*. Obtenido de larepublica.co: https://www.larepublica.co/finanzas/banca-tradicional-cede-espacio-a-neobancos-los-cuales-tienen-25-millones-de-usuarios-3381865

Athanasopoulos, R. J. (2018). *Forecasting: Principles and Practice (2nd ed).* Melbourne: OTexts.

Bishal, D., Bidesh, R., Subir, D., & Taha Selim, U. (2022). Forecasting ethanol demand in India to meet future blending targets: A comparison of ARIMA and various regression models. *Energy Reports*, 411-418.

Chatfield, C. &. (2013). *The Analysis of Time Series: An Introduction.*

Chatfield, C. (2003). The Analysis of Time Series: An Introduction. Chapman and Hall/CRC.

Douglas C, M., Cheryl L, J., & Murat, K. (2009). Introduction to Time Series Analysis and Forecasting.

Esan, C. (16 de 08 de 2019). *Conexión Esan*. Obtenido de Conexión Esan: https://www.esan.edu.pe/conexion-esan/como-elegir-la-mejor-tecnica-de-forecasting

Everette S, G. J., & Ed, M. (1985). Forecasting trends in Time Series.

Guillermo, C., Alejandra, E., Juan Carlos, G., & C. Z. (2009). ANÁLISIS DE SERIES TEMPORALES. 14.

Jr Everette S, G. (1985). Exponential smoothing: The state of the art. Journal of Forecasting.

Nathalia Morales Arévalo. (2022). *La Republica*. Obtenido de https://www.larepublica.co/finanzas/creditos-de-libranza-en-sector-bancario-mantienen-tasas-que-oscilan-entre-12-y-33-3436523

Oracle. (2022). *Oracle*. Obtenido de https://www.oracle.com/co/industries/financial-services/banking/Aplicativo/core-banking-software/#rc30p4

Ortiz, J. A. (05 de 2023). *www.cienciadedatos.net*. Obtenido de https://www.cienciadedatos.net/documentos/py27-forecasting-series-temporales-python-scikitlearn.html

Rameshwar, G., Shriya, B., Girish Rao, S. N., & Ramya, S. (2021). Machine Learning Algorithms for Time Series. 9.

Rob Hyndman, A. B. (2008). *Forecasting with Exponential Smoothing: The State Space Approach.* Springer.

Rob J, H., & Anne B, K. (2006). Another look at measures of forecast accuracy. International journal of forecasting.

Sebastian Raschka, Y. L. (2022). *Machine Learning with Pytorch and Scikit-Learn.* Birmingham: Packt.

TransUnion. (2 de Junio de 2022). *TransUnion.* Obtenido de Tendencias del mercado de crédito al primer trimestre del 2022: https://noticias.transunion.co/tendencias-del-mercado-de-credito-al-primer-trimestre-del-2022/

Verbel Castellar, A. J. (2007). EI tiempo estandar controlado bajo la perspectiva de un análisis multivariado. En U. A. Caribe, *PROSPECTIVA.*